

Desconfia: Plataforma Inteligente para Identificação de Indícios de Golpes Digitais

Componentes do grupo:

Gustavo Rissoli Vicente
Hellen Karla Costa Campos Moraes de Melo
José Henrique Bessi Wolkers
Kaio Soares Pacheco
Yasmim Luiz dos Santos

Repositório no GitHub:

<https://github.com/yasmim-luizds/desconfia>

1. Escopo

O **Desconfia** é uma aplicação web voltada ao apoio na identificação de indícios de golpes digitais presentes em mensagens textuais recebidas por diferentes meios de comunicação, como aplicativos de mensagens, SMS, e-mail e redes sociais. O projeto se insere no contexto de Tecnologia e Inovação, com recorte em cibersegurança, área contemplada pelo edital do Projeto Integrador IV. O trabalho também atende à proposta da disciplina de desenvolver uma aplicação real de Inteligência Artificial relacionada a um problema concreto de uma comunidade, combinando IA e Testes de Software.

O problema central abordado pelo projeto é a dificuldade que usuários podem enfrentar para reconhecer, de forma rápida e compreensível, indícios de engenharia social e possíveis fraudes em mensagens recebidas por canais digitais. Diante de conteúdos que simulam comunicações legítimas e utilizam estratégias como urgência, ameaça, personificação ou solicitação de informações, nem sempre o usuário possui elementos suficientes para avaliar imediatamente o risco envolvido.

O sistema permitirá que o usuário realize cadastro e login, insira uma mensagem considerada suspeita e receba uma análise realizada com apoio de um modelo de linguagem acessado através da **Groq API**. O resultado será apresentado em três níveis de risco, sendo eles: **baixo, médio ou alto**, acompanhado dos principais sinais identificados, uma explicação e recomendações preventivas.

A classificação não será apresentada como confirmação de que determinada mensagem constitui fraude, mas como uma **avaliação de risco**, considerando que modelos de Inteligência Artificial podem apresentar erros, falsos positivos e falsos negativos.

A aplicação também permitirá consultar o histórico de análises e fornecer feedback sobre os resultados. O armazenamento de informações seguirá o princípio da minimização de dados, evitando manter conteúdo desnecessário ou informações pessoais além do necessário para o funcionamento da plataforma.

A aplicação será desenvolvida com **React, JavaScript e Vite** no frontend, **Python e FastAPI** no backend, **PostgreSQL e SQLAlchemy** para persistência dos dados e **Groq API** para o componente de Inteligência Artificial. Serão utilizados **Pytest e Vitest** para os testes automatizados.

O MVP será limitado à análise de **mensagens textuais**. Recursos como imagens, capturas de tela, QR Codes, áudio, vídeo e análise automática de páginas externas não farão parte do escopo inicial.

2. Justificativa

A utilização de meios digitais está cada vez mais presente em atividades de comunicação, pagamentos, compras, relacionamentos pessoais e acesso a diferentes serviços. Aplicativos de mensagens, redes sociais, e-mails e plataformas digitais facilitam a comunicação, mas também podem ser utilizados como canais para tentativas de fraude e engenharia social.

A relevância desse problema também pode ser observada em dados recentes relacionados às fraudes digitais. Segundo Capobianco (2025), com base em dados do Anuário Brasileiro de Segurança Pública, o Brasil registrou aproximadamente **281 mil casos de estelionato por meios eletrônicos em 2024**, representando crescimento de **17% em relação ao ano anterior**. Esses números demonstram que fraudes praticadas por meios digitais constituem um problema atual e relevante.

Uma das dificuldades relacionadas a esse problema é que mensagens mal-intencionadas nem sempre apresentam características imediatamente evidentes. Em determinadas situações, o conteúdo pode utilizar uma linguagem semelhante à empregada por empresas ou pessoas conhecidas, explorar acontecimentos cotidianos ou combinar diferentes técnicas de persuasão para tornar a solicitação aparentemente legítima.

O Ministério das Comunicações (2026) aponta que tentativas de phishing podem ocorrer por canais como e-mail, SMS, aplicativos de mensagens e redes sociais, buscando obter informações pessoais, bancárias ou credenciais. O CERT.br também recomenda atenção a solicitações inesperadas e a verificação das informações antes de realizar pagamentos, fornecer dados ou executar ações solicitadas por terceiros (CERT.br, s.d.).

Mensagens fraudulentas nem sempre apresentam sinais evidentes. Uma tentativa pode combinar personificação, urgência e solicitação financeira de maneira semelhante a uma comunicação legítima. Por isso, uma solução baseada apenas na busca por palavras específicas pode não ser suficiente para interpretar o contexto completo.

Nesse cenário, o uso de um modelo de linguagem pode contribuir para identificar relações entre diferentes elementos da mensagem e produzir uma explicação compreensível sobre os sinais encontrados. Entretanto, a Inteligência Artificial será utilizada apenas como **ferramenta de apoio**, não substituindo a avaliação humana, os canais oficiais das instituições ou mecanismos especializados de segurança.

O Desconfia busca, portanto, oferecer uma segunda análise ao usuário e, ao explicar os motivos da classificação, também contribuir para a conscientização sobre padrões utilizados em golpes digitais.

3. Metodologia

O desenvolvimento do Desconfia seguirá uma abordagem **incremental e orientada à experimentação**, permitindo que as funcionalidades sejam implementadas, testadas e aprimoradas progressivamente durante o semestre.

Inicialmente serão definidos os principais cenários relacionados ao problema, incluindo mensagens com urgência, personificação, solicitações financeiras, pedidos de dados pessoais, credenciais ou códigos de autenticação.

Em seguida serão desenvolvidos o frontend, o backend e a persistência dos dados. Serão implementados cadastro, login, histórico e controle de acesso, adotando práticas básicas de segurança, como armazenamento de senhas por meio de hash e minimização dos dados persistidos.

Posteriormente será realizada a integração com a **Groq API**. O modelo receberá instruções para analisar exclusivamente o conteúdo da mensagem e retornar uma resposta estruturada contendo nível de risco, sinais identificados, explicação e recomendações. A resposta será validada pelo backend antes de ser apresentada ao usuário.

Também serão considerados riscos de **prompt injection**, tratando o conteúdo enviado pelo usuário apenas como dado para análise e não como uma instrução capaz de modificar o comportamento definido para o modelo.

Paralelamente ao desenvolvimento serão realizados testes automatizados sobre funcionalidades críticas, como cadastro, autenticação, validação das entradas, acesso ao banco, criação de análises, tratamento de erros e comportamento da interface.

O componente de Inteligência Artificial será avaliado separadamente por meio de uma **avaliação específica da IA (eval)**. Para isso, será criado um conjunto de mensagens previamente classificadas, contendo exemplos legítimos, suspeitos e ambíguos. Os resultados produzidos pela IA serão comparados às classificações esperadas.

Também serão utilizadas variações das mesmas mensagens, incluindo abreviações e erros de escrita, para verificar a robustez do modelo. Serão observados falsos positivos, falsos

negativos, consistência das classificações, validade do formato retornado e resistência a tentativas de prompt injection.

As explicações serão avaliadas verificando se estão relacionadas aos sinais realmente presentes na mensagem e se evitam informações não sustentadas pelo conteúdo. As recomendações deverão ser preventivas e coerentes com práticas seguras.

Caso seja viável durante o semestre, avaliações com usuários poderão ser realizadas de forma complementar. A validação técnica, entretanto, será baseada principalmente no conjunto controlado de avaliação.

4. Plano de trabalho

O desenvolvimento será organizado de acordo com os três checkpoints definidos para a disciplina.

Até a entrega do **C1, em 18/09/2026**, serão definidos o problema, escopo, metodologia, comunidade impactada, indicadores previstos, tecnologias e organização inicial do projeto.

Após o C1 será iniciada a implementação da aplicação, começando pela preparação do frontend e backend, integração com PostgreSQL e desenvolvimento do cadastro e autenticação.

Na etapa seguinte será implementado o fluxo principal de análise e realizada a integração com a Groq API. Antes do **C2, em 30/10/2026**, o objetivo será possuir um protótipo funcional capaz de receber uma mensagem, realizar a análise com IA e apresentar o resultado, acompanhado dos primeiros testes automatizados e casos de eval.

Após o C2 serão aprimorados o histórico, feedback, interface, testes e conjunto de avaliação da IA. Também serão realizados ajustes de segurança e tratamento de erros.

Na etapa final será realizado o deploy da aplicação, consolidação das métricas de avaliação e documentação do projeto, preparando o MVP para a entrega **C3, em 04/12/2026**.

5. Comunidade impactada e indicadores previstos

A comunidade impactada pelo Desconfia será composta inicialmente por **estudantes universitários e familiares adultos que utilizam com frequência aplicativos de mensagens, redes sociais, e-mail, serviços bancários e outras plataformas digitais em seu cotidiano.**

Os integrantes dessa comunidade podem apresentar diferentes níveis de conhecimento sobre segurança digital. Alguns usuários podem reconhecer com maior facilidade sinais presentes em mensagens suspeitas, enquanto outros podem possuir menor familiaridade com esse tipo de situação.

A necessidade considerada pelo projeto está relacionada principalmente à dificuldade de avaliar rapidamente a confiabilidade de uma mensagem antes de tomar determinada ação. Uma pessoa pode receber uma solicitação de transferência financeira, um contato informando mudança de número, uma notificação de suposto bloqueio de conta ou uma mensagem solicitando informações pessoais e não possuir elementos suficientes para avaliar imediatamente o risco envolvido.

Como a participação direta da comunidade poderá não ser viável durante o desenvolvimento, a avaliação será baseada principalmente em **indicadores técnicos e de potencial de apoio à comunidade**. Os resultados não serão apresentados como comprovação de mudança de comportamento da comunidade, mas como evidências sobre a capacidade da ferramenta de analisar mensagens e oferecer informações úteis aos usuários.

Os principais indicadores previstos serão:

Indicador	Forma de medição
Taxa de classificação correta	Percentual de casos em que a classificação corresponde ao resultado previamente definido
Falsos positivos	Mensagens legítimas classificadas com risco elevado
Falsos negativos	Mensagens suspeitas classificadas como baixo risco

Robustez e consistência	Comparação entre mensagens equivalentes ou escritas de formas diferentes
Qualidade das explicações e recomendações	Verificação da coerência com os sinais existentes e das orientações preventivas apresentadas
Respostas válidas	Percentual de respostas completas e compatíveis com o formato esperado
Resistência a prompt injection	Percentual de casos adversariais em que as instruções originais são preservadas

Esses indicadores serão calculados utilizando um conjunto de avaliação contendo mensagens legítimas, suspeitas, ambíguas, variações linguísticas e casos adversariais. Os resultados serão utilizados para identificar limitações e orientar ajustes no componente de Inteligência Artificial ao longo do desenvolvimento.

Referências

BRASIL. Ministério das Comunicações. Ataque Phishing: como identificar tentativas de fraude na internet. Brasília, DF, 14 jul. 2026. Disponível em:

https://www.gov.br/mcom/pt-br/noticias/noticias_alt/2026/julho/ataque-phishing-como-identificar-tentativas-de-fraude-na-internet. Acesso em: 9 set. 2026.

CAPOBIANCO, João Pedro. Golpes nas redes: Brasil registrou 281 mil casos de estelionato digital em 2024. *Lupa*, 24 jul. 2025. Atualizado em: 16 jun. 2026. Disponível em:

<https://www.agencialupa.org/jornalismo/2025/07/24/golpes-nas-redes-brasil-registrou-281-mil-casos-de-estelionato-digital-em-2024/>. Acesso em: 12 set. 2026.

CERT.br — CENTRO DE ESTUDOS, RESPOSTA E TRATAMENTO DE INCIDENTES DE SEGURANÇA NO BRASIL. Cartilha de Segurança para Internet. São Paulo: NIC.br.

Disponível em: <https://cartilha.cert.br/fasciculos/golpes/fasciculo-golpes.pdf>. Acesso em: 13 set. 2026.